Predicción de pCR con una CNN desde cero — Informe del caso BreastDCEDL

30 de octubre de 2026

Álvaro González Fernández · Aprendizaje Automático · Ingeniería Matemática, UAX

Resumen

En el conjunto de test independiente, evaluado una sola vez y con el modelo congelado, mi modelo final alcanza un **AUC por paciente de 0,679 (IC95 0,596-0,760)**, frente a 0,691 en la validación cruzada de 5 folds. La diferencia entre validación y test es de solo 0,012, de modo que el procedimiento de selección no infló los resultados.

El modelo final combina por fusión tardía (regresión logística) una CNN 2D de 98.049 parámetros entrenada desde cero con las variables clínicas de la paciente: subtipo HR/HER2, volumen tumoral y edad. Supera de forma significativa a la referencia «solo cohorte» (+0,136; IC95 +0,017 a +0,249). Sin embargo, la imagen aporta poco sobre la clínica: la CNN sola obtiene 0,572 y la mejora del combinado frente al modelo clínico es de +0,005, con un intervalo que incluye el cero.

Con el umbral fijado en train (especificidad ≥ 0,85), el modelo detecta 15 de las 53 pacientes con pCR (sensibilidad 0,28) con una precisión de 0,45, frente a una prevalencia del 30 %. Es una señal real pero moderada, sin utilidad clínica demostrada.

Lo que más valor tiene del trabajo es el proceso. Audité los datos antes de entrenar, comparé todas las variantes con validación cruzada por paciente frente a la referencia «solo cohorte» y detecté que elegir la época con la propia validación inflaba el AUC. Diseñé una receta de entrenamiento que mantiene juntas las curvas de entrenamiento y validación, y separé estrictamente la selección del modelo (solo train) de la evaluación final (test, una vez). Todo se acompaña de una aplicación web desplegada que aplica exactamente el mismo preprocesado que el entrenamiento.

1. Problema clínico y objetivo

Mi objetivo era estimar, a partir de la resonancia DCE-MRI realizada **antes** del tratamiento neoadyuvante, la probabilidad de que una paciente con cáncer de mama alcance la respuesta patológica completa (pCR). Tenía que hacerlo con una CNN construida desde cero y convertirla en una aplicación web robusta.

La pCR significa que, tras el tratamiento, el patólogo no encuentra cáncer invasivo residual en el tejido extraído de la mama y los ganglios. Es un resultado favorable (y = 1), pero no equivale a curación ni a supervivencia. La etiqueta solo se conoce después de la cirugía, mientras que la imagen se adquiere antes. La red, por tanto, no «ve» la respuesta: intenta relacionar el aspecto inicial del tumor con un resultado futuro.

Una probabilidad de 0,45 significa que el modelo estima P(pCR = 1) = 0,45 para esa entrada. No es una recomendación terapéutica y en ningún caso permite omitir la cirugía, que es la que confirma la respuesta. El trabajo es educativo y no tiene validez clínica.

Por eso me planteé dos objetivos a la vez:

1. **Técnico:** una CNN 2D desde cero (sin modelos preentrenados ni transfer learning), con un único logit y BCEWithLogitsLoss, cuyas curvas de entrenamiento y validación se mantuvieran juntas y cuya ROC quedara claramente por encima de la referencia «solo cohorte».
2. **Metodológico:** que cada cifra fuera honesta. Separé por paciente, no usé test para ninguna decisión y medí siempre frente a la referencia que se obtiene sin mirar la imagen.

2. Investigación previa: artículos y repositorios

Antes de diseñar nada, y otra vez a mitad del trabajo cuando los resultados se estancaron, revisé la literatura del propio dataset y el código público de sus autores. Varias decisiones del modelo final salen directamente de esa revisión.

Fuente	Qué encontré	Qué tomé para mi trabajo
Fridman et al., *Scientific Data* (2026): artículo del dataset	2.070 pacientes de I-SPY1, I-SPY2 y Duke; versión MinCrop de 256 × 256 centrada en el tumor con PRE, EARLY y LATE; particiones estratificadas	Entender cómo se construyeron los PNG. Encontré que la ventana de 256 se recorta del corte original sin reescalar, centrada en la caja del tumor
Fridman et al., arXiv 2506.12190 (2025): ViT para pCR	Vision Transformer sobre la fusión RGB de las tres fases: AUC de test 0,72 en total, 0,78 en I-SPY2, 0,68 en I-SPY1 y **0,54 en Duke**. Con variables clínicas (Random Forest en dos etapas) I-SPY2 sube a 0,85	Una cota de referencia realista, conseguida con un modelo grande que aquí está prohibido. Que Duke esté cerca del azar incluso para ellos. Y, sobre todo, que las variables clínicas aportan mucha señal: de ahí mi fusión tardía
Repositorio de los autores (naomifridman/BreastDCEDL)	Cuadernos de preprocesado por cohorte, recorte alrededor del tumor sin reescalar, metadatos con la caja del tumor	El **recorte centrado de 160 px sin reescalar** (mi modelo final) y la prueba de usar solo los cortes centrales del tumor
Conjuntos originales en TCIA (I-SPY1, I-SPY2, Duke)	Protocolos y equipos distintos; Duke sin segmentación completa, solo la caja de la lesión mayor	Tratar la cohorte como posible variable de confusión y comparar siempre con «solo cohorte»
NCI y guía de la FDA sobre pCR	Definición patológica de la pCR y su papel como variable de valoración en ensayos	El lenguaje y los límites de interpretación que muestra la

Fuente	Qué encontré	Qué tomé para mi trabajo
	neoadyuvantes	aplicación

Del artículo del ViT también aprendí a leer con cuidado las cifras llamativas. El AUC de 0,94 que aparece en el resumen corresponde a un subgrupo (HR+/HER2− de I-SPY2 con variables clínicas); en el test completo de ese subtipo, el resultado es 0,64.

Comenté también estrategias con compañeros de clase y adopté algunas **ideas**, nunca su código ni sus resultados: entrenar un número fijo de épocas sin elegir la mejor, regularizar con fuerza y usar en cada época solo unos cortes al azar de cada paciente. La implementación y la evaluación son mías.

Otras ideas las valoré y las descarté antes de entrenar. La segmentación con U-Net o con pérdida Dice exige máscaras manuales que no tengo, y Dice sirve para segmentar, no para dar una probabilidad por paciente. Borrar el corazón por su tamaño podía borrar también un tumor grande. Los módulos de atención tipo CBAM quedaron como línea futura.

3. Datos: auditoría, separación por paciente y clases

Los datos están limpios, pero contienen dos trampas: la tasa de pCR cambia con la cohorte y las imágenes de cada cohorte se ven distintas. Una red podría acertar reconociendo el estudio de origen en lugar del tumor.

3.1 Composición y clases

Conjunto	Pacientes	Cortes	Sin pCR	Con pCR	Tasa de pCR
Train	1.097	10.945	775	322	29,4 %
Test	176	1.758	123	53	30,1 %

Cohorte (train)	Pacientes	Tasa de pCR
I-SPY2	784	32 %
I-SPY1	104	25 %
Duke	209	21 %

Hay un desbalance de aproximadamente 2,4 a 1. Un modelo que dijera siempre «no pCR» tendría un 70 % de accuracy y sensibilidad cero, así que no uso la accuracy para decidir nada. El cociente pos_weight = N0/N1 varía entre 2,33 y 2,55 según el fold y se calcula siempre sobre la partición de entrenamiento.

El subtipo tumoral separa mucho más que la imagen. En train, la tasa de pCR es del 43 % en HER2+, del 38 % en triple negativo y del 14 % en HR+/HER2−. Este hallazgo anticipó que las variables clínicas serían la principal fuente de señal.

3.2 Separación por paciente

La unidad estadística es la paciente, no el corte. Cada paciente aporta unos 10 cortes muy parecidos entre sí; si sus cortes cayeran a ambos lados de una partición, la red reconocería su anatomía y el resultado sería una fuga de información.

- Usé los 5 folds por paciente del propio dataset (columna `fold`, unas 219 pacientes por fold) para toda la validación interna. Las 14 comprobaciones de integridad salieron correctas: ninguna paciente aparece en dos conjuntos ni en dos folds, y la etiqueta es la misma en todos sus cortes.
- Las métricas se calculan por paciente, con la media de las probabilidades de sus cortes, y los intervalos de confianza con bootstrap que remuestrea pacientes completas.
- El test se cargó una única vez, al final (sección 7). La validación privada del profesorado no la he visto.

3.3 Auditoría numérica

- PRE < EARLY en el 99,4 % de las pacientes. Las 7 excepciones se mantienen y se documentan. LATE < EARLY (lavado del contraste) en el 18-20 %, un patrón con posible valor biológico.
- Diferencias de adquisición: Duke tiene menos realce EARLY − PRE e I-SPY1 un PRE más brillante. Por eso todas las comparaciones se hacen contra la referencia **«solo cohorte»**, que asigna a cada paciente la tasa de pCR de su cohorte en train.

3.4 Auditoría visual

Revisé a mano los cortes centrales de 60 pacientes de train (20 por cohorte) y encontré tres problemas que los números no mostraban:

- **Una estructura grande y muy realzada detrás de la pared torácica**, compatible con el corazón, aparece en 13 de 20 imágenes de I-SPY2 y de Duke y en ninguna clara de I-SPY1. Es una pista ligada a la cohorte, justo lo que no quiero que la red aprenda.
- **Movimiento entre fases:** hay bordes dobles en el realce en 13 de 60 imágenes, repartidos por las tres cohortes.
- **Encuadre variable:** en 912 de las 1.097 pacientes el PNG es el corte entero y, en I-SPY, el tumor puede estar en cualquier parte de la imagen.

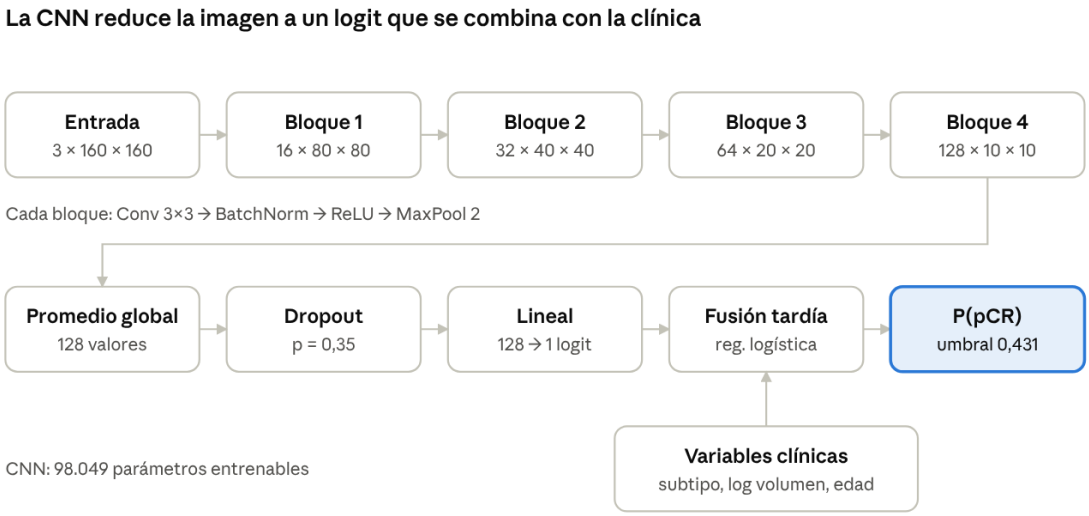
Además, comprobé que las columnas `sraw`, `eraw`, `scol` y `ecol` de patients.csv son la caja del tumor. Una vez llevada al sistema de coordenadas del PNG (ventana de 256 y giro de 90°), cae sobre la lesión en las 40 pacientes con lesión visible, sin ningún error. El tamaño de la caja se relaciona con la pCR (AUC 0,44: tumores grandes, menos pCR); el tamaño del encuadre, no (0,50).

3.5 Preprocesado

Cada corte son tres PNG de 8 bits y 256 × 256 que apilo en el orden PRE, EARLY y LATE y divido entre 255. Los tres canales son instantes de tiempo, no colores, así que no aplico la normalización de ImageNet ni aumento de color, y cualquier transformación geométrica es idéntica en las tres fases. Una única función (`preprocesado.py`) la comparten el entrenamiento, la evaluación y la aplicación.

4. Arquitectura de la CNN desde cero

La red tiene **4 bloques convolucionales idénticos, un promedio global y una sola neurona de salida: 98.049 parámetros entrenables**. La hice pequeña a propósito, porque solo hay unas 880 pacientes de entrenamiento por fold y una red grande memoriza antes, como comprobé después con el quinto bloque.



arquitectura del modelo final · 4 bloques convolucionales + fusión con la clínica

La imagen pasa por los cuatro bloques y el promedio global hasta un único logit; la regresión logística lo combina con las variables clínicas (sección 6).

Capa	Operación	Salida (entrada 160 × 160)	Parámetros
Entrada	PRE, EARLY, LATE	3 × 160 × 160	—
Bloque 1	Conv 3×3 (16) → BatchNorm → ReLU → MaxPool 2	16 × 80 × 80	448 + 32
Bloque 2	Conv 3×3 (32) → BatchNorm → ReLU → MaxPool 2	32 × 40 × 40	4.640 + 64
Bloque 3	Conv 3×3 (64) → BatchNorm → ReLU → MaxPool 2	64 × 20 × 20	18.496 + 128
Bloque 4	Conv 3×3 (128) → BatchNorm → ReLU → MaxPool 2	128 × 10 × 10	73.856 + 256
GAP	Promedio global por canal	128	—
Dropout	p = 0,35 (0,3 en la línea base)	128	—
Lineal	128 → 1 (logit)	1	129
Total			**98.049**

Con la imagen completa de 256 × 256 la red es la misma (16 × 128 × 128 tras el bloque 1, 128 × 16 × 16 tras el 4): el promedio global hace que el número de parámetros no dependa del tamaño de la entrada.

Por qué cada pieza:

- **Convoluciones 3×3 con padding 1:** detectan patrones locales (bordes, textura, realce) compartiendo pesos en toda la imagen y conservan el tamaño hasta el pooling. Los filtros se duplican en cada bloque (16 → 128) mientras la resolución se reduce a la mitad, un equilibrio clásico entre detalle y abstracción.
- **BatchNorm:** estabiliza la escala de las activaciones y permite una tasa de aprendizaje de 10^{-3} sin divergir.
- **ReLU:** no linealidad simple y sin saturación en la parte positiva.
- **MaxPool 2:** reduce la resolución y amplía el campo receptivo; tras 4 bloques cada neurona final «ve» unos 46 × 46 píxeles de la entrada.
- **Promedio global (GAP) en lugar de aplanar:** pasa de 12.800 valores a 128, sin miles de pesos en la capa final; con un Flatten la capa lineal tendría 100 veces más parámetros y memorizaría más.
- **Dropout antes de la capa lineal:** apaga al azar neuronas durante el entrenamiento para que la decisión no dependa de unas pocas.
- **Un único logit y BCEWithLogitsLoss:** el enunciado lo exige y es numéricamente más estable que aplicar la sigmoide y luego la entropía cruzada. La probabilidad se obtiene con la sigmoide solo en inferencia.
- **Inicialización:** la de PyTorch por defecto (Kaiming uniforme), adecuada para ReLU. La pérdida del primer lote (0,62-0,63) es la esperada para una red que aún no sabe nada.

Antes de entrenar en serio comprobé que el circuito funcionaba con una **prueba de memorización**: entrenando una y otra vez sobre solo 2 lotes, la pérdida bajó de 0,61 a 0,05 en 100 iteraciones. La red es capaz de aprender, de modo que los problemas posteriores no se debían a un error de código.

5. Entrenamiento: decisiones y experimentos

Entrené 21 configuraciones en 81 ejecuciones completas (15 de ellas con validación cruzada de 5 folds). El hallazgo central es que **la imagen sola aporta poca señal y la red memoriza enseguida**, y que el AUC de 0,60 que obtenía al principio estaba inflado por elegir la época con la misma validación con la que se medía. Cambié una sola cosa cada vez respecto a la referencia anterior.

5.1 Configuración de partida

Hiperparámetro	Línea base	Modelo final (receta)	Motivo
Optimizador	Adam	AdamW	AdamW aplica el weight decay de forma desacoplada; con weight decay 0 da pesos idénticos a Adam (comprobado)
Tasa de aprendizaje	10^{-3} constante	10^{-3} con bajada lineal a 0	Valor estándar para Adam con BatchNorm; la bajada hace que las últimas actualizaciones sean muy pequeñas
Weight decay	0	10^{-2}	10^{-4} no cambiaba nada (5.2)

Hiperparámetro	Línea base	Modelo final (receta)	Motivo
Dropout	0,3	0,35	Más regularización en la única capa densa
Tamaño de lote	32	32	Estabilidad de BatchNorm y memoria de sobra en la GPU
Cortes por paciente y época	todos (~10)	3 al azar, distintos en cada época	Menos repetición de cortes casi idénticos
Épocas	hasta 30, early stopping con paciencia 7 (10 en validación cruzada)	12 fijas	Ver 5.4
Criterio de época	mejor AUC de validación	ninguno: la última	Elimina el sesgo optimista de elegir época
Pérdida	BCEWithLogitsLoss sin pos_weight	igual	Ver 5.2
Semilla	42	42	Entrenamiento determinista: dos ejecuciones iguales dan las mismas pérdidas
Aumento de datos	no	no	Descartado por validación cruzada (5.3)

5.2 Primeros experimentos con un solo fold

La línea base, entrenada primero en la CPU del portátil, paró en la época 17 con la mejor en la 10: **AUC 0,603 (IC95 0,52-0,69)**. Pero «solo cohorte» (0,534) caía dentro del intervalo, y las curvas mostraban sobreajuste a partir de la época 8. Ya en la GPU, probé tres cambios por separado sobre el fold 0:

Variante (fold 0)	AUC	Sensibilidad / especificidad con 0,5	Lectura
Línea base sin pos_weight	0,598	0,06 / 0,93	Referencia
pos_weight = N0/N1 (comparación obligatoria)	0,579	0,84 / 0,26	Desplaza todas las probabilidades hacia arriba (media 0,62 frente a 0,30) sin ordenar mejor.

Variante (fold 0)	AUC	Sensibilidad / especificidad con 0,5	Lectura
			Es un cambio de umbral encubierto y empeora la calibración (Brier 0,325 frente a 0,209)
Aumento geométrico (volteo y ±10°, igual en las 3 fases)	0,577	0,00 / 0,99	Frena la memorización, pero no mejora la validación
Weight decay 10^{-4}	0,586	0,20 / 0,85	Casi idéntico a la línea base: valor demasiado pequeño

Ninguna diferencia superaba el ruido: con 219 pacientes de validación, diferencias menores de unos 0,07 de AUC son compatibles con el azar. Por eso decidí **no usar pos_weight** y gestionar el desbalance con el umbral, que además conserva probabilidades interpretables. También decidí pasar a validación cruzada.

5.3 Validación cruzada y el sesgo de elegir la época

Con los 5 folds, la línea base obtuvo 0,597 de media (DT 0,033) y el aumento 0,582, así que **descarté el aumento**. Al analizar las curvas encontré el problema importante: el AUC salta de época en época entre 0,48 y 0,60, y el early stopping se queda con el pico. **La media del AUC de todas las épocas era 0,539, por debajo de «solo cohorte» (0,549).** El 0,60 dependía de elegir el mejor examen entre treinta.

Cambié el criterio por un AUC suavizado (media de cada época con sus vecinas) y, para medir de forma justa, junté las predicciones out-of-fold de los 5 folds y calculé un único AUC con IC95 por bootstrap sobre las 1.097 pacientes. Con esa medida probé las ideas de arquitectura y de entrada:

Variante (5 folds, criterio suavizado)	AUC por paciente	Inicio medio del sobreajuste
Línea base	0,551	época 6,8
Aumento de datos	0,565	≥ 7,4
5 bloques (245.889 parámetros, campo receptivo ~94 px)	0,538	3,8
Realce explícito (PRE, EARLY−PRE, LATE−EARLY)	0,567	5,4
Recorte por la caja del tumor (reescalado a 128)	0,551	6,8
«solo cohorte»	0,523	—

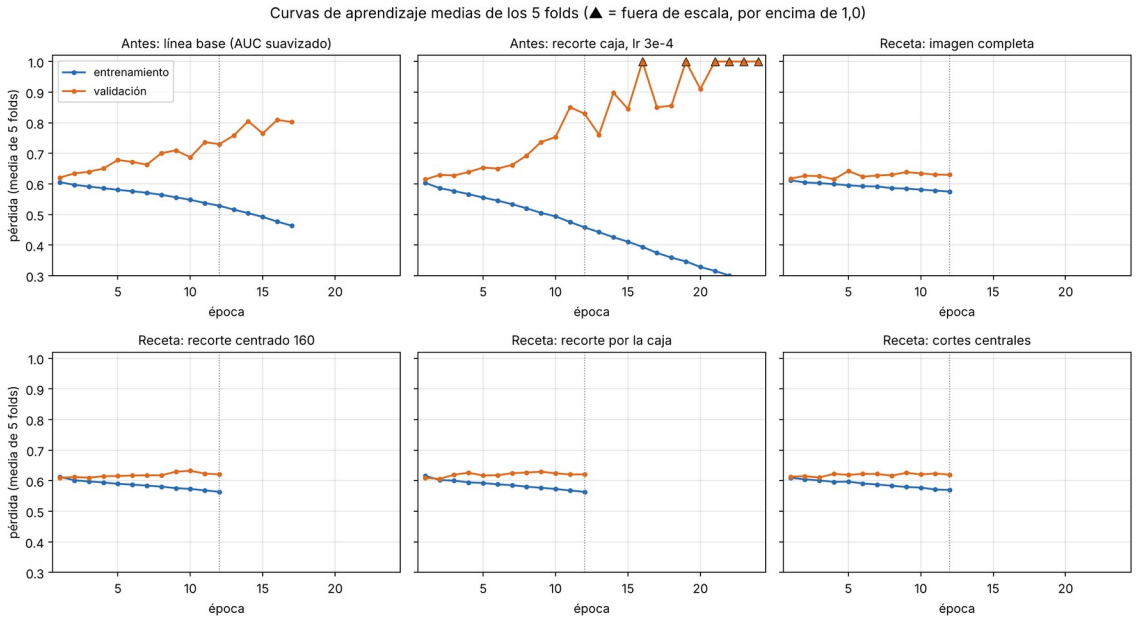
Ninguna variante superó a «solo cohorte» con un intervalo que excluyera el cero. Más capacidad (5 bloques) solo hizo que la red memorizara antes. La lección fue que **el sobreajuste era un síntoma, no la causa**: la red memoriza porque en la imagen hay poca señal útil y mucho ruido. Una tasa de aprendizaje de $3{\cdot}10^{-4}$ sin early stopping lo empeoró: la pérdida de validación se disparó por encima de 1.

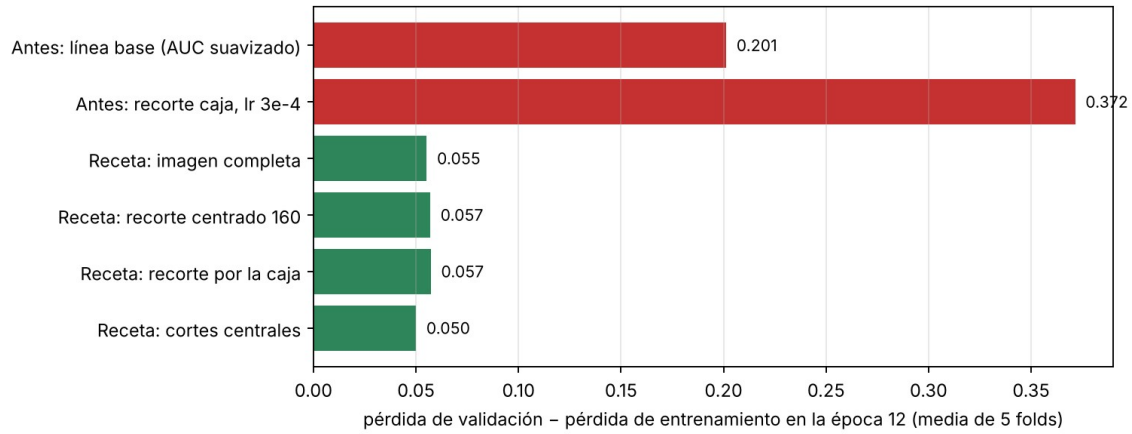
5.4 La receta regularizada

Para el último bloque de experimentos combiné cinco medidas que atacan la memorización desde ángulos distintos:

1. **12 épocas fijas y la última, sin elegir:** desaparece el sesgo optimista y el modelo no puede llegar a la zona de memorización.
2. **3 cortes al azar por paciente y época:** 2.634 imágenes por época en lugar de 8.759. La red ve menos veces cada corte y cortes distintos en cada época, así que le cuesta más aprenderse a una paciente.
3. **Tasa de aprendizaje con bajada lineal hasta 0:** los últimos pasos apenas mueven los pesos, de modo que el modelo final no depende de un salto de los últimos lotes.
4. **Weight decay 10^{-2}:** penaliza los pesos grandes cien veces más que la prueba anterior.
5. **Dropout 0,35.**

La apliqué a cuatro entradas: la imagen completa, un recorte de 160 × 160 centrado en la caja del tumor sin reescalar (idea tomada del repositorio de los autores), el recorte por la caja y solo los 4 cortes centrales del tumor.





Configuración (5 folds)	AUC CNN por paciente (IC95)	Distancia val − entr en la época 12	Inicio medio del sobreajuste
Antes: línea base	0,551	0,201	6,8
Antes: recorte por la caja, lr $3{\cdot}10^{-4}$	—	0,372	—
Receta: imagen completa	0,544 (0,506-0,579)	0,055	~11
Receta: recorte centrado 160	**0,559 (0,522-0,594)**	0,057	~11
Receta: recorte por la caja	0,552	0,057	—
Receta: 4 cortes centrales	0,548	0,050	—

La receta cumple su objetivo: la distancia entre las curvas en la época 12 baja de 0,20-0,37 a 0,05-0,06, y la pérdida de entrenamiento desciende poco a poco con la de validación acompañándola. El AUC de la CNN sola apenas cambia (0,544-0,559): la receta no crea señal, pero hace que la poca que hay sea estable y honesta. Elegí el recorte centrado de 160 porque obtuvo el AUC más alto, aun sabiendo que la diferencia con las demás cabe en el ruido; el test, al final, lo confirmó.

5.5 Comprobación con 24 épocas

Para confirmar que 12 épocas no eran un corte arbitrario, repetí la receta con 24. La pérdida de entrenamiento bajó el doble (0,097 frente a 0,049) y la validación la acompañó hasta la época 13; a partir de ahí las curvas se separaron (distancia final 0,142). El AUC no mejoró (0,552 frente a 0,559) y el modelo combinado tampoco (0,687 frente a 0,692). Entrenar más solo añadía memorización, así que mantuve las 12 épocas.

6. Fusión con variables clínicas y modelo final

Como la imagen sola se quedaba cerca de «solo cohorte» y la literatura del dataset mostraba el peso de las variables clínicas, combiné la CNN con ellas. **El modelo combinado obtiene 0,691 en validación**

cruzada, frente a 0,686 del clínico solo y 0,545 de la CNN sola. El profesorado facilita estas variables en la defensa, así que el modelo puede usarlas de forma legítima en la aplicación.

6.1 Cómo se combinan

Usé una **fusión tardía**: una regresión logística (L2, C = 1) cuyas entradas son las variables clínicas y la salida de la CNN.

- **Subtipo HR/HER2:** tres indicadores 0/1 (HR+/HER2−, HER2+, triple negativo).
- **Volumen tumoral:** log(1 + volumen), porque la distribución es muy asimétrica.
- **Edad.**
- **logit de la probabilidad de la CNN.**

Las variables se estandarizan con la media y la desviación de train, y un valor que falta se sustituye por la media de entrenamiento. **La raza no se usa**: no es una causa biológica de la respuesta y su uso introduciría un sesgo metodológico y ético.

Para que la regresión no viera probabilidades «tramposas», la entrené con las predicciones **out-of-fold**: cada corte de train lleva la probabilidad que le dio la CNN de un fold en el que esa paciente no se usó para entrenar. Escalador y regresión se ajustan dentro de cada fold con los mismos 5 folds por paciente. La fusión se ajusta por corte, porque la aplicación analiza un corte suelto.

6.2 Resultados en validación cruzada (train)

Modelo	AUC por paciente (IC95)
Solo cohorte	0,523 (0,484-0,560)
Solo CNN (receta, centrado 160)	0,545 (0,508-0,584)
Clínico	0,686 (0,653-0,720)
Combinado	**0,691 (0,659-0,725)**

La diferencia pareada combinado − clínico es +0,006 (IC95 −0,005 a +0,015): la CNN apenas añade información. Los coeficientes estandarizados tienen sentido clínico: HR+/HER2− resta (−0,45), HER2+ (+0,28) y triple negativo (+0,21) suman, un volumen mayor (−0,24) y una edad mayor (−0,21) restan, y la CNN suma +0,17.

Con una CNN anterior (recorte por la caja, lr $3{\cdot}10^{-4}$) el combinado llegaba a 0,707, con una mejora sobre el clínico de +0,021 que sí era significativa. La descarté porque esa red sobreajustaba mucho (distancia entre curvas de 0,37) y sus probabilidades out-of-fold venían de épocas elegidas con la propia validación, el mismo sesgo optimista que había detectado antes. Preferí una cifra algo menor pero creíble.

6.3 Umbral

Fijé el umbral con las predicciones out-of-fold de train, nunca con test: **el de mayor sensibilidad entre los que dan especificidad ≥ 0,85**. Resultado: 0,4311 por paciente y 0,4330 por corte, con sensibilidad

0,335 y precisión 0,48 en validación cruzada. Como se eligen y se miden con las mismas predicciones, esas cifras de train son algo optimistas. La razón de priorizar la especificidad está en la sección 10.

6.4 Congelación del modelo

El modelo final quedó congelado antes de mirar el test:

- **CNN:** la ejecución del fold 0 de la receta con recorte centrado de 160 (12 épocas, última época). La regla «fold 0» la fijé antes de ver resultados. No la reentrené con todo train porque los coeficientes de la fusión se aprendieron con salidas out-of-fold de modelos entrenados con 4/5 de los datos; una red entrenada con todo podría dar probabilidades más extremas y la fórmula dejaría de encajar.
- **Fusión:** regresión reajustada con todo train, guardada con su escalador, coeficientes y umbrales en `modelo_app/fusion.json`.
- **Huellas:** SHA-256 de `modelo.pt` (e86a36a9…) y de `fusion.json` (42dc2d90…), y un commit de git anterior a la evaluación. El script de evaluación se niega a ejecutarse si el modelo es provisional, si las huellas no coinciden, si hay código sin commit o si el test ya se evaluó.

7. Resultados en el test independiente

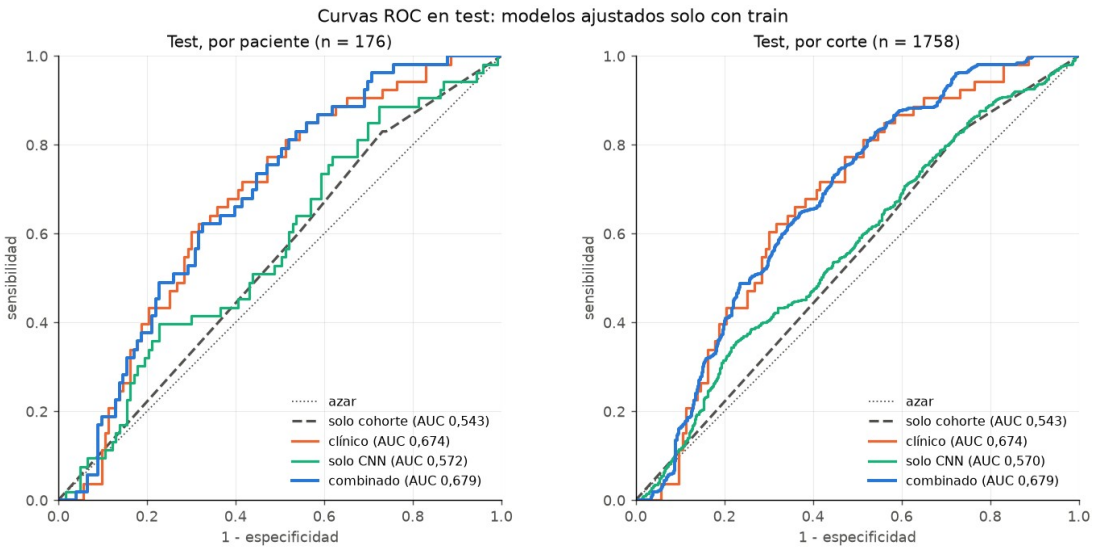
Evalué el test **una sola vez**, con el modelo congelado y sin ajustar ni elegir nada con él: 176 pacientes (53 con pCR) y 1.758 cortes. **El combinado obtiene un AUC por paciente de 0,679 (IC95 0,596-0,760), solo 0,012 menos que en validación cruzada.** El test confirma la validación y, con ella, el procedimiento de selección.

7.1 Discriminación

Modelo	AUC validación cruzada	AUC test (IC95)	AP test	Brier test
Solo cohorte	0,523	0,543 (0,461-0,622)	0,321	0,210
Solo CNN	0,545	0,572 (0,477-0,661)	0,349	0,209
Clínico	0,686	0,674 (0,590-0,758)	0,400	0,197
Combinado	**0,691**	**0,679 (0,596-0,760)**	**0,406**	**0,196**

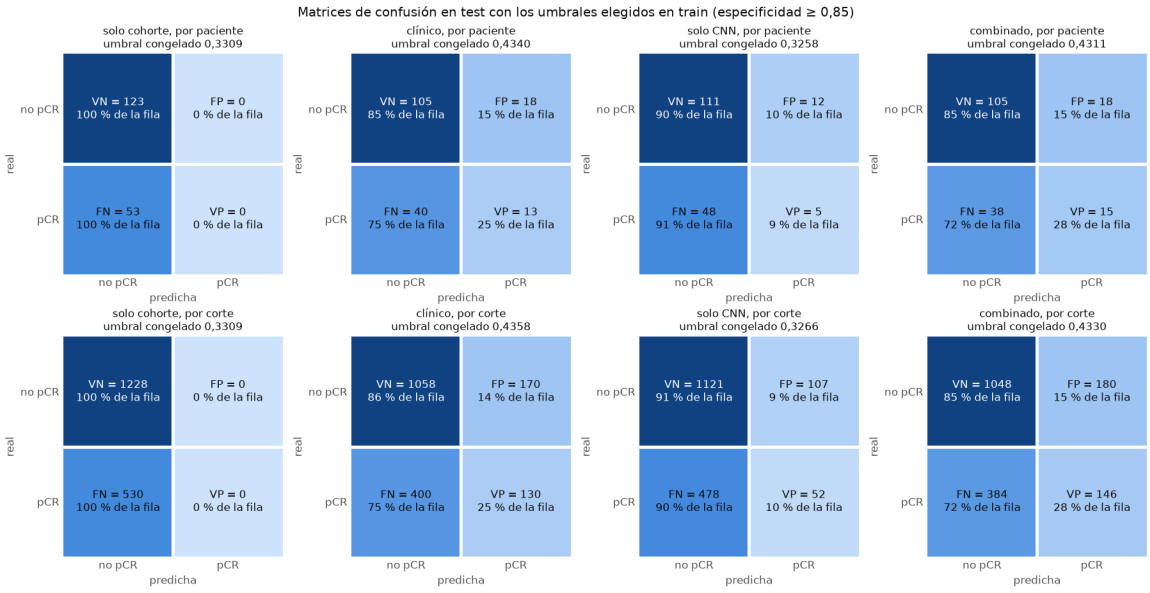
Referencias del azar: AP = 0,301 (la tasa de pCR) y Brier = 0,210 (predecir siempre la tasa).

Diferencia pareada en test	AUC (IC95)
Combinado − solo cohorte	**+0,136 (+0,017 a +0,249)**
Clínico − solo cohorte	+0,131 (+0,013 a +0,250)
Combinado − solo CNN	+0,107 (0,000 a +0,218)
Combinado − clínico	+0,005 (−0,021 a +0,029)



El combinado supera claramente a «solo cohorte», con un intervalo que no toca el cero. La CNN sola, en cambio, no se distingue del azar con 176 pacientes (su IC95 baja a 0,477), y su aporte sobre el clínico es el mismo que en validación cruzada: pequeño y no significativo. Las métricas por corte son prácticamente idénticas a las de paciente (combinado 0,679), así que la aplicación, que trabaja con un corte, se comporta como el modelo por paciente.

7.2 Matriz de confusión con el umbral congelado

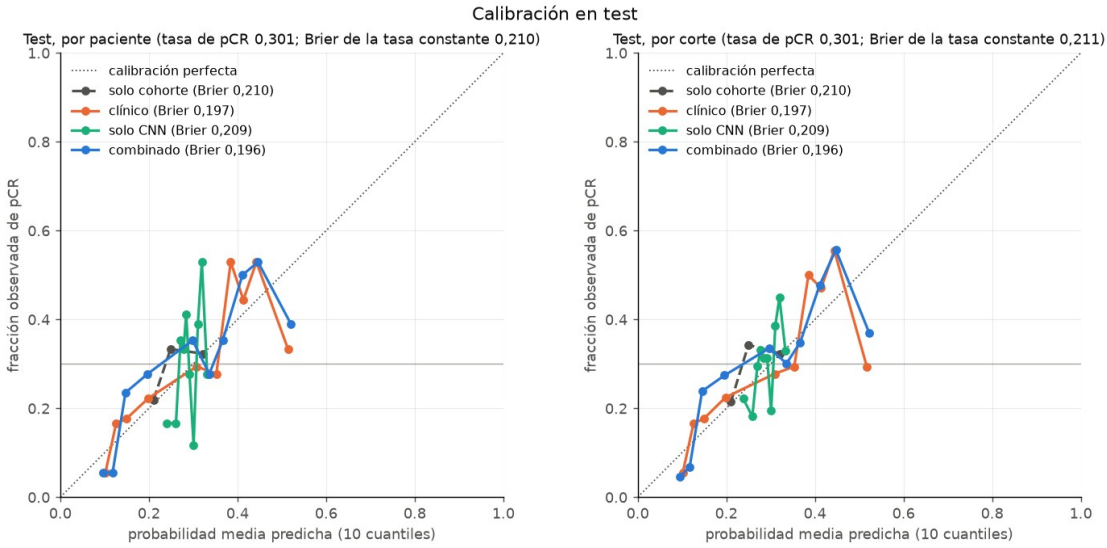


Modelo (por paciente)	Umbral	VP	FN	FP	VN	Sensibilidad	Especificidad	Precisión	VPN
Clínico	0,434	13	40	18	105	0,245	0,854	0,419	0,724
Combinado	**0,431**	**15**	**38**	**18**	**105**	**0,283**	**0,854**	**0,455**	**0,734**

Modelo (por paciente)	Umbral	VP	FN	FP	VN	Sensibilidad	Especificidad	Precisión	VPN
						(0,16-0,41)	**(0,79-0,91)**		

La especificidad en test (0,854) coincide con el 0,85 fijado en train, así que el umbral se traslada bien a datos nuevos. El combinado encuentra dos pCR más que el clínico con los mismos falsos positivos. Cuando dice «pCR» acierta el 45 % de las veces, frente al 30 % de la prevalencia, pero se le escapan 38 de las 53 pacientes que sí respondieron. «solo cohorte» no clasifica a nadie como pCR porque solo produce tres valores posibles y ninguno supera su umbral; su papel es servir de referencia de AUC.

7.3 Calibración



La probabilidad media predicha del combinado (0,293) es casi la tasa real (0,301) y su Brier (0,196) mejora el de predecir siempre la tasa (0,210). Las curvas siguen la diagonal de forma razonable, pero el modelo nunca supera una probabilidad de aproximadamente 0,5: nunca está «seguro» de una pCR. Es coherente con una señal moderada, y por eso la aplicación muestra siempre la probabilidad con su incertidumbre en lugar de solo la clase.

7.4 Por cohorte

Cohorte (test)	Pacientes (pCR)	Clínico	Solo CNN	Combinado
I-SPY2	99 (32)	0,728	0,612	0,736
I-SPY1	35 (12)	0,801	0,449	0,783
Duke	42 (9)	0,492	0,633	0,515

El modelo funciona en I-SPY y falla en Duke, igual que el ViT de los autores (0,54 en Duke). En Duke la CNN da 0,63 mientras el clínico se queda en 0,49, pero con 9 pCR los intervalos son enormes (0,43-0,82 para la CNN): es una hipótesis para estudiar, no un hallazgo.

8. GPU, entorno y reproducibilidad

La GPU del laboratorio acelera el entrenamiento **22 veces** respecto a la CPU de mi portátil con la misma configuración, y eso fue lo que hizo viable la validación cruzada de todas las variantes.

	Portátil (CPU)	Laboratorio (GPU)
Dispositivo	AMD Ryzen 5 3500U, 8 hilos	AMD Radeon RX 6700 XT (ROCm), CPU Intel Core Ultra 5 245
Sistema	Windows	Linux
Entorno	Python 3.11.0, PyTorch 2.14.1+cpu	Python 3.11.16, PyTorch 2.14.1+rocm7.14 (conda)
Línea base, lote 32: tiempo por época	626,7 s (~10,4 min)	28,5 s
Línea base: tiempo total (17 épocas)	177,6 min	8,1 min
Modelo final (receta, 12 épocas, lote 32)	—	5,4 s por época, 65 s en total
Memoria máxima	—	343 MB de GPU; 2,1 GB de RAM

Speedup = t_CPU / t_GPU = 626,7 / 28,5 ≈ 22. La receta es aún más rápida porque cada época usa 3 cortes por paciente y la entrada es de 160 × 160; la primera época tarda unos 6 s más por el calentamiento de la librería MIOpen. PyTorch usa la GPU AMD a través de la misma API `cuda`, sin variables de entorno especiales.

Para que todo se pueda reproducir:

- **Semilla 42** para pesos, barajado y muestreo de cortes, con generadores separados para que activar una opción no altere el resto. Comprobé que en esta GPU el entrenamiento es determinista: la ejecución del fold 0 de la validación cruzada es idéntica, época a época, a la primera ejecución en GPU.
- **Cada ejecución guarda** su `config.json` (comando, hiperparámetros, entorno, commit de git y SHA-256 de los pesos), el registro, las métricas por época y sus gráficas con escalas fijas. Una tabla, `experimentos.csv`, reúne todas las ejecuciones.
- **`train.py` se niega a arrancar si hay código sin commit**, de modo que cada resultado se asocia a un código concreto.
- **Separación de datos sensibles:** el repositorio solo contiene resultados agregados. Las predicciones por paciente y el dataset, que llevan etiquetas, nunca se suben.
- **El código está en scripts `.py`**, no en cuadernos, y el entrenamiento se lanza con un único comando por ejecución. El del modelo final es: `python train.py --epocas 12 --criterio ultima --lr 1e-3 --lr-lineal --weight-decay 1e-2 --dropout 0.35 --cortes-por-paciente 3 --recorte-centrado 160 --fold 0`.

9. Aplicación web

La aplicación, hecha con Streamlit y desplegada en Streamlit Community Cloud, ejecuta exactamente el mismo modelo y el mismo preprocesado que el entrenamiento. **La probabilidad que muestra coincide con la del pipeline de entrenamiento con una diferencia menor de 10^{-5}**, comprobado con una batería de pruebas automatizada.

- **URL de la aplicación:** casocancercnn-wxbzjp2szt25nxqmidpwfy.streamlit.app · código en github.com/AlvaroGlezFdez/caso_cancer_CNN
- **Pesos del modelo:** huggingface.co/AlvaroGlez/pcr-cnn-breastdcedl

9.1 Qué hace

1. **Entrada:** tres PNG de un corte (PRE, EARLY, LATE) o uno de los ejemplos incluidos, y las variables de la paciente en CSV o en un formulario: subtipo, volumen, edad y caja del tumor.
2. **Validación paso a paso**, con un mensaje claro en español para cada problema: fichero vacío, contenido que no es PNG (por ejemplo, un JPEG renombrado), cabecera dañada o fichero truncado, más de 2 MB, dimensiones distintas de 256 × 256, PNG animado, 16 bits, 1 bit, color o transparencia, fase ausente, la misma imagen en dos fases, ficheros de cortes distintos y fases intercambiadas. También valida las variables: subtipo desconocido, valores imposibles y caja incoherente.
3. **Visualización:** las tres fases por separado y el mapa de realce, con zoom y cursor sincronizados, la ventana de 160 × 160 que recibe la red marcada sobre la imagen, la curva cinética de un píxel (ascendente, meseta o lavado) y un mapa Grad-CAM orientativo.
4. **Resultado:** probabilidad de pCR del modelo combinado, clase según el umbral congelado y la contribución de cada parte al resultado (subtipo, volumen, edad, imagen). Muestra también la probabilidad de la imagen sola y la del modelo clínico.
5. **Datos técnicos:** umbral, SHA-256 del modelo, dispositivo de inferencia (CPU), tiempo de respuesta, hiperparámetros del entrenamiento y métricas de validación cruzada y de test.
6. **Otras páginas:** el modelo (arquitectura y coeficientes), rendimiento (ROC, matriz de confusión con umbral ajustable, calibración), datos, cronología de experimentos y limitaciones.

9.2 Robustez y seguridad

- La inferencia se ejecuta con `model.eval()` y sin gradientes. La salida es determinista: la misma entrada da siempre la misma probabilidad.
- Los pesos se cargan solo tras comprobar su SHA-256, y la aplicación rechaza un modelo con opciones de preprocesado que no conoce.
- No acepta rutas del sistema, no ejecuta nada de lo que se sube y limita el tamaño y el formato de los ficheros.
- El modelo final necesita la caja del tumor para recortar la ventana. Si falta, la aplicación no predice y explica por qué; nunca centra la ventana en otro sitio por su cuenta.
- Una prueba automatizada simula la defensa: cinco muestras seguidas de cinco pacientes distintas, con errores intercalados, sin reiniciar la aplicación.

- Un aviso visible en todas las páginas recuerda que es una herramienta educativa, que muestra una estimación incierta y que no tiene validez clínica. Ni la validación privada ni ninguna etiqueta están en el repositorio ni dentro de la aplicación.

10. Discusión: preguntas del enunciado

¿Qué error es más relevante? ¿Cambia según el uso?

Depende del uso, y por eso lo decidí antes de fijar el umbral. Si el modelo se usara para identificar pacientes con probabilidad alta de pCR, por ejemplo para estudiar una desescalada en un ensayo, el error grave es el **falso positivo**: predecir pCR en una paciente a la que le queda tumor podría llevar a tratarla de menos. Por eso fijé una especificidad mínima de 0,85 y acepté una sensibilidad baja: en test, 18 falsos positivos frente a 105 verdaderos negativos.

Si el uso fuera el contrario, detectar a las pacientes con baja probabilidad de respuesta para ofrecerles un ensayo o intensificar la vigilancia, el error que preocupa sería el **falso negativo respecto a la pCR**: una paciente que iba a responder podría recibir cambios innecesarios. Ahí convendría otro umbral, siempre elegido en train. En ningún caso este modelo debería cambiar un tratamiento de forma automática.

¿La red aprende biología tumoral o diferencias entre cohortes?

No tengo evidencia de que la CNN aprenda biología de forma sólida, y sí de que existen pistas de cohorte que podría aprovechar.

- **A favor de la cohorte:** la tasa de pCR cambia por cohorte (32 % en I-SPY2 frente a 21 % en Duke), las intensidades de adquisición difieren y la estructura cardíaca aparece en I-SPY2 y Duke pero no en I-SPY1. En el fold 3, «solo cohorte» (0,593) superó a todas las CNN.
- **En contra:** las probabilidades medias de la CNN eran parecidas en las tres cohortes, así que no se limita a reconocer el estudio. La señal de imagen más clara apareció dentro de I-SPY2, donde la cohorte es constante (AUC 0,61 con 784 pacientes en las primeras pruebas).
- **Lo que hice para reducirlo:** comparar siempre con «solo cohorte», analizar por cohorte y recortar una ventana centrada en el tumor que deja fuera la mayor parte del tórax.

La señal que sí es claramente biológica es la clínica: el subtipo HR/HER2 y el tamaño del tumor tienen la relación con la pCR que describe la literatura.

¿Cómo afecta tener diez observaciones correlacionadas por paciente?

Los 10 cortes de una paciente no son 10 casos independientes: comparten tumor, etiqueta y anatomía. El tamaño muestral efectivo se acerca al número de pacientes (1.097), no al de cortes (10.945). Por eso separé siempre por paciente, calculé las métricas principales por paciente, construí los intervalos con un bootstrap que remuestrea pacientes completas y, en la receta, mostré solo 3 cortes al azar por paciente y época para no repetir imágenes casi idénticas. Si hubiera tratado los cortes como independientes, los intervalos habrían salido mucho más estrechos de lo que justifican los datos.

¿Está calibrada la probabilidad?

Razonablemente, sí. En test, la probabilidad media (0,293) coincide casi con la tasa real (0,301) y el Brier (0,196) mejora el de predecir siempre la tasa (0,210). Dos decisiones lo hicieron posible: no usar pos_weight, que inflaba la probabilidad media hasta 0,62, y no elegir la época, porque la línea base con la mejor época daba una media de 0,44 frente a una tasa de 0,29. La limitación es el rango: el modelo nunca pasa de aproximadamente 0,5.

¿Qué evidencia faltaría para hablar de utilidad clínica, equidad y generalización externa?

- **Generalización externa:** mi test procede de las mismas tres cohortes que el entrenamiento. Haría falta validarlo en otros hospitales, equipos y protocolos, y después de forma prospectiva.
- **Utilidad clínica:** un AUC no dice si el modelo mejora decisiones. Haría falta comparar con la valoración de radiólogos y onólogos, un análisis de beneficio neto y un ensayo cuya pregunta sea si usarlo mejora los resultados.
- **Equidad:** comprobar el rendimiento por subtipo, edad, cohorte y equipo con muestras suficientes. Con 176 pacientes los subgrupos tienen intervalos demasiado anchos, como muestra Duke.
- **Muestra y estabilidad:** más pacientes para estrechar los intervalos y repetir con varias semillas, para medir la variabilidad del propio entrenamiento.

11. Limitaciones, ética y conclusiones

11.1 Limitaciones

- **La imagen aporta poco.** La CNN sola no se distingue del azar en test (IC95 0,477-0,661) y el modelo funciona sobre todo gracias a las variables clínicas.
- **Una CNN 2D sobre un corte.** El tumor es tridimensional y la cinética completa tiene más de tres instantes; un corte suelto pierde parte de esa información.
- **Depende de la caja del tumor.** El recorte de 160 necesita la caja, que en la práctica tendría que dibujar un radiólogo. En el 5 % de las pacientes de test la caja no cabe entera en la ventana.
- **Una sola semilla y un solo fold para la CNN final.** No he medido la variabilidad del entrenamiento con varias semillas.
- **Selección mínima con la validación cruzada:** elegí la variante centrada entre cuatro, con diferencias dentro del ruido; el test confirmó que la elección no estaba inflada.
- **Test de las mismas cohortes, con pocos casos por subgrupo** (9 pCR en Duke), y sin validación externa.
- **Problemas de la imagen sin resolver:** movimiento entre fases y diferencias de intensidad entre cohortes. Alinear las fases o normalizar el realce por paciente quedaron como trabajo futuro, junto con los módulos de atención y los modelos 3D.

11.2 Ética y licencia

Las imágenes están desidentificadas y se usan solo para docencia. No he intentado reidentificar a ninguna paciente, no publico etiquetas, predicciones por paciente ni la validación privada, y la aplicación

no diagnostica ni recomienda tratamientos. Mantengo la atribución a BreastDCEDL y a las fuentes originales y la licencia CC BY-NC 4.0 en los ejemplos que incluye la aplicación. Un buen resultado retrospectivo no demuestra seguridad, causalidad ni utilidad clínica.

11.3 Conclusiones

1. **Predecir la pCR solo con la resonancia previa al tratamiento es muy difícil con una CNN pequeña entrenada desde cero:** la mejor CNN se queda en un AUC de 0,55-0,57, cerca de la referencia «solo cohorte».
2. **El sobreajuste era un síntoma de la poca señal, no la causa.** Regularizar más o ampliar la red no mejoró la validación. Una receta de entrenamiento corta y regularizada sí consiguió curvas de entrenamiento y validación juntas y una señal estable.
3. **Medir bien cambia las conclusiones.** Elegir la época con la propia validación inflaba el AUC de 0,54 a 0,60. Comparar con «solo cohorte», validar por paciente y usar el test una sola vez fueron decisivos para obtener cifras creíbles.
4. **Las variables clínicas son la principal fuente de señal.** El modelo combinado logra un AUC de 0,679 en test, significativamente superior a «solo cohorte» y casi igual que en validación cruzada (0,691), con una probabilidad bien calibrada.
5. **El resultado es retrospectivo y educativo.** La aplicación lo presenta como una estimación incierta, reproducible y con sus límites a la vista, nunca como una decisión clínica.

Referencias

1. N. Fridman et al., “BreastDCEDL: A standardized deep learning-ready breast DCE-MRI dataset of 2,070 patients”, *Scientific Data*, 2026. DOI: 10.1038/s41597-026-06589-6.
2. N. Fridman et al., *BreastDCEDL: A Deep Learning–Ready Breast DCE-MRI Dataset*, Zenodo. DOI: 10.5281/zenodo.18114231.
3. N. Fridman, B. Solway, T. Fridman, I. Barnea y A. Goldstein, “BreastDCEDL: A Comprehensive Breast Cancer DCE-MRI Dataset and Transformer Implementation for Treatment Response Prediction”, arXiv:2506.12190, 2025. arxiv.org/abs/2506.12190.
4. Repositorio de código de BreastDCEDL: github.com/naomifridman/BreastDCEDL.
5. D. Newitt, N. Hylton et al., *Breast DCE-MRI Data and Segmentations from Patients in the I-SPY 1/ACRIN 6657 Trials*, The Cancer Imaging Archive, 2016. DOI: 10.7937/K9/TCIA.2016.HdHpgJLK.
6. W. Li et al., *I-SPY 2 Breast Dynamic Contrast Enhanced MRI Trial (ISPY2)*, The Cancer Imaging Archive, 2022. DOI: 10.7937/TCIA.D8Z0-9T85.
7. A. Saha et al., *Dynamic contrast-enhanced magnetic resonance images of breast cancer patients with tumor locations (Duke-Breast-Cancer-MRI)*, The Cancer Imaging Archive, 2021. DOI: 10.7937/TCIA.e3sv-re93.
8. National Cancer Institute, “Pathologic complete response”, *Dictionary of Cancer Terms*. cancer.gov.
9. U.S. Food and Drug Administration, *Pathological Complete Response in Neoadjuvant Treatment of High-Risk Early-Stage Breast Cancer: Use as an Endpoint to Support Accelerated Approval*, 2020. fda.gov.

Datos usados bajo licencia CC BY-NC 4.0, con atribución a BreastDCEDL y a las fuentes originales.